



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico II

Programacion SIMD

Organización del Computador II
Segundo Cuatrimestre de 2015

Integrante	LU	Correo electrónico
Leandro Raffo		
Maximiliano Fernández Wortman		
Uriel Rozenberg		



Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359

<http://www.fcen.uba.ar>

Índice

1. Introduccion	3
2. Implementacion	3
2.1. Diferencia	3
2.2. Blur gaussiano	4
3. Resultados	6
3.1. Diferencia	6
3.2. Blur	11
4. Conclusión	13
Referencias	13

1. Introduccion

En este trabajo práctico realizamos la implementación de dos filtros de imagenes, con tal de ver que tan eficiente puede llegar a ser (o no) SIMD, los filtros son la diferencia de imagenes y el blur gaussiano, los cuales fueron implementados en lenguaje C (gcc y clang) y assembly, haciendo uso de instrucciones vectoriales. Luego comparamos la performance de estas implementaciones sobre diferentes imagenes y usando herramientas probabilísticas y estadísticas.

2. Implementacion

2.1. Diferencia

Descripción de un ciclo de la iteración del filtro diferencia.

Primero pedimos memoria para declarar las máscaras que vamos a usar y armamos el stackframe (omitido)

```
section .rodata
mascara_copia_pixels db 2,2,2,2,6,6,6,6,10,10,10,10,14,14,14,14
mascara_asigna_alpha db 0,0,0,255,0,0,0,255,0,0,0,255,0,0,0,255
```

Luego de armar el stackframe tenemos

```
mov r12, rdx
mov eax, r8d
mov ecx, ecx
mul rcx
xor r15, r15
```

r12 apunta a la matriz resultado, ecx tiene la cantidad de filas, y la parte baja de rax(eax) tiene la cantidad de columnas. Al hacer mul rcx se tiene filas*columnas en rdx:rax, como movimos cosas de 32 bits obtenemos la multiplicación en rax, que es lo que vamos a usar, junto a r15 para iterar (notar que tenemos en cuenta para esto que los movimientos de registros entre dwords limpian la parte alta de los registros de 64bits, es decir extendemos el número usando que son enteros positivos). Ahora entramos al ciclo.

```
.ciclo:
    cmp r15, rax
    JE .fin
```

Comparamos si r15 es igual a rax en tal caso ya hicimos la diferencia sobre todos los pixeles y termina el ciclo. El ciclo sigue con

```
movdqu xmm3 , [RDI + r15*4]
movdqu xmm15, [RSI + r15*4]
movdqu xmm14, xmm15
pminub xmm15, xmm3
pmaxub xmm3 , xmm14
psubb xmm3 , xmm15
movdqu xmm4, xmm3
movdqu xmm5, xmm3
```

Movemos a xmm3 los primeros 4 pixeles de la primera matriz y a xmm15 los primeros 4 de la segunda matriz a comparar, estos ocupan respectivamente 16 bytes en memoria (brga por 4). Después Guardamos en xmm14 el valor de xmm15 y hacemos un pminub entre xmm15 y xmm3 lo cual deja en xmm15 el mínimo byte a byte. Lo mismo para xmm3 pero con pmaxub es decir este tiene el máximo byte a byte. Hacemos esto porque queremos calcular el valor absoluto de la forma $|x - y| = \max(x, y) - \min(x, y)$. Concluimos esta idea haciendo psubb entre xmm3 que tenia el máximo y xmm15 que tenia el mínimo y finalmente guardamos el resultado en xmm4, 5 para operar en la siguiente parte.

```

pslldq xmm4, 1
pslldq xmm5, 2
movdqu xmm6, xmm5
pmaxub xmm6, xmm4
pmaxub xmm6, xmm3
pshufb xmm6, [mascara_copia_pixels]
paddsb xmm6, [mascara_asigna_alpha]
movdqu [r12 + r15*4], xmm6
add r15d, 4
jmp .ciclo

```

Ahora shifteamos con packed shift `xmm4, 5` uno y dos bytes respectivamente de forma de poder tomar el máximo de entre `r g b` en paralelo, es decir 4 pixels a la vez. Por ejemplo, el primer byte de `xmm4` tiene al byte de `r`, y el de `xmm6` tiene al byte de `g`, de forma que al hacer `pmaxub` entre `xmm6` y `xmm4` nos deja en el primer byte de `xmm6` (y cada 3 bytes) $\max(r_n, g_n)$ donde $n = \{1, 2, 3, 4\}$ indican los pixeles que levantamos. Los demas bytes de este registro no nos interesan. Repetimos esto entre `xmm6` y `xmm3`, pasa de vuelta lo mismo pero ahora tenemos en el primer byte de `xmm6` (y cada 3 bytes) $\max(r_n, g_n, b_n)$ con $n = \{1, 2, 3, 4\}$. Ahora tenemos que mover este máximo a las 3 coordenadas `r, g y b`, hacemos esto mediante la mascara `mask5` y mediante `trans2` sumamos con saturación con tal de dejar en `alpha` el valor 255. Copiamos los 16 bytes correspondientes (con el offset adecuado) en la matriz destino, sumamos 4 a `r15d` y saltamos para, si es necesario, volver a hacer el ciclo completo.

2.2. Blur gaussiano

El blur gaussiano consta de dos ciclos uno anidado sobre el otro, el anidado itera sobre el kernel y el que anida itera sobre la matriz, usamos SIMD para hacer los calculos sobre cuatro pixeles en simultaneo (es decir sobre 16 componentes en total), además en vez de hacer offsets para atras como el codigo en C nos movemos siempre para adelante, por ejemplo, empezamos en el pixel 0 y recorremos la submatriz que va de $0, 2r$ en filas y $0, 2r$ en columnas, donde r es el radio, a la par de la matriz del kernel (que también tiene este tamaño) haciendo las multiplicaciones sobre cuatro pixeles y acumulandolas, luego cuando terminamos de iterar sobre el kernel, insertamos en los cuatro pixel destino, que esta en la posición (r, r) hasta $(r + 3, r + 3)$, luego aumentamos la columna y seguimos este proceso hasta el ancho $-2r - 16$ donde nos paramos en la proxima fila y repetimos hasta llegar a la altura $-2r$, es decir siempre que insertamos los pixeles estamos en rango. Podemos hacer 4 pixeles a la vez pues el ancho es un múltiplo de 4. Ahora pasamos a describir más en detalle las operaciones que usamos para esto.

Nota: Siempre vamos a poner el código sobre un pixel porque las operaciones sobre los otros 3 son las mismas operaciones sobre distintos registros en seguidilla, vamos a aclarar estos casos en la explicación.

Antes de entrar al ciclo preparamos algunos registros para saber hasta donde iterar, tenemos que: `rax` guarda el último valor hasta el que vamos a recorrer que es igual a $[(\text{filas} - 2r) * \text{columnas}] - 2r$, `rbp` va a guardar hasta donde vamos a hacer cada subciclo es decir $(2r + 1)^2$, `r11` tiene el valor $2r$, `r12` la matriz fuente, `r13` la matriz destino, `r8` la cantidad de columnas y `rbx (ebx)` el offset necesario para insertar el pixel en la matriz destino.

```

.ciclo_kernel:
    cmp rcx, rbp
    je .insert
    mov r9, rsi
    add r9, rdi
    movd     xmm0, [ r12 + r9 ]
    punpcklbw xmm0, xmm8
    punpcklwd xmm0, xmm8
    cvtdq2ps  xmm0, xmm0

```

Primero verificamos si tenemos que insertar el pixel, para esto comparamos `rcx`, el registro que cuenta sobre el tamaño del kernel contra `rbp` que mantenía hasta donde teníamos que iterar para haber recorrido el kernel, si no, levantamos de memoria 4 bytes y los desempaquetamos a double words y convertimos a float, repetimos esto con

los offsets $r12 + r9 + 4/8/12$, es decir los primeros 16 bytes, y guardando en los registros `xmm4`, `xmm5` y `xmm6` respectivamente.

```
movd    xmm1, [ r10 + rcx*4 ]
movq    xmm3, xmm1
pslldq  xmm3, 4
padd    xmm3, xmm1
pslldq  xmm3, 4
padd    xmm3, xmm1
mulps   xmm0, xmm3
addps   xmm2, xmm0
```

Como `rcx` itera el kernel linealmente, movemos el valor de la matriz de convolución apuntado por `rcx` con `movd` (un float por eso el `*4`) a `xmm1`, shifteamos 4 bytes con `pslldq`, ya que queremos propagar este valor para que multiplique las 3 componentes (rgb) a la vez, movemos un quadword shifteamos y hacemos un packed add (queremos copiar el valor del float) shifteamos `xmm3` y volvemos a sumar una vez más, para que cada doubleword de `xmm3` tenga el float. Luego multiplicamos el registro con el valor del pixel del kernel, contra los valores del pixel que desempaquetamos en `xmm0` dejando en `xmm0` este valor y lo acumulamos en `xmm2`. De vuelta repetimos esto con `xmm4/5/6` y acumulamos en `xmm7/9/10`

```
cmp rdx, r11
je .sumar_fila_kernel
add rdx, pixel_size
inc rcx
add rsi, pixel_size
jmp .ciclo_kernel
```

`rdx` mantiene el contador para iterar sobre la fila, si este es igual a `2r` saltamos a `sumar_fila_kernel` de lo contrario adelantamos `rdx` y `rsi` en `pixel_size` (que es un `%define` con el valor 4) y entramos al ciclo de vuelta.

```
.sumar_fila_kernel:
xor rdx, rdx
sub rsi, r11
add rsi, r8
inc rcx
jmp .ciclo_kernel
```

En `sumar_fila` limpiamos `rdx`, para volver a poder iterar de 0 a `2r`, le restamos `2r` a `rsi`, este iteraba sobre la fila para la matriz mas grande y le sumamos al mismo la cantidad de columnas, es decir `rsi` apunta al comienzo de la fila siguiente, incrementamos `rcx` así en el proximo ciclo apunta a la siguiente fila tambien y saltamos al ciclo de vuelta.

```
.insert:
    pxor     xmm4, xmm4
    cvtps2dq xmm2, xmm2
    packusdw xmm2, xmm4
    packuswb xmm2, xmm4
    movd     xmm7, ebx
    add      rbx, rdi
    movd     [ r13 + rbx ], xmm2
    ..
    movd     [ r13 + rbx + 4], xmm7
    ..
    movd     ebx, xmm7
    pxor     xmm7, xmm7
    xor      rsi, rsi
    xor      rcx, rcx
    cmp      rdi, r15
    je       .sumar_fila
    add      rdi, pixel_size
    jmp      .ciclo_matriz
```

En `.insert` hacemos casi lo contrario a levantar, convertimos los floats empaquetados que estaban en `xmm2` a `doublewords` empaquetados y re-empaquetamos a `word` y luego a `byte`. Luego sumamos `rbx` e `rdi` para obtener la posición en la que vamos a insertar el pixel (los 4 bytes) e insertamos el pixel, de vuelta repitiendo para los 4 pixeles con el offset `+4/8/12`. Una vez que esto pasa ponemos `rsi` y `rcx` en 0 y vemos si llegamos a la ultima columna que teníamos que iterar, si pasa esto saltamos a `sumar_fila` sino sumamos `4*pixel_size` a `rdi` y saltamos al ciclo del kernel de vuelta.

```
.sumar_fila:
    add      rdi, r11
    add      r15, r8
    jmp      .ciclo_matriz
```

En `.sumar_fila` lo que hacemos es sumarle a `rdi` lo que faltaba para llegar a la proxima columna, `2r` y le sumamos a `r15` la cantidad de columnas, `r15` en este caso mantiene (acorde al `rdi`) hasta que columna tenemos que iterar. Basicamente `r15` empieza en `cols - 2r` y se le van sumando el total de columnas, en la segunda iteracion tiene `2cols - 2r` etc. Aca saltamos a `ciclo_matriz` y no `ciclo_kernel`, este contiene lo siguiente.

```
.ciclo_matriz:
    cmp      rdi, rax
    jg       .end
```

Si `rdi` es mayor que `rax` (que marcaba el ultimo pixel sobre el que podíamos iterar) saltamos al final, desarmamos el stackframe y retornamos.

3. Resultados

3.1. Diferencia

Nota: todos los tests fueron corridos sobre una PC con procesador Intel Core2Duo E8400 que cuenta con 64kb de cache L1 para datos, 64kb de cache L1 para instrucciones y 6mb de cache L2 compartido para data e instrucciones por los dos nucleos.

Para analizar las implementaciones de C y assembly, corrimos 1000 iteraciones de cada implementación de diferencia sobre una imagen de 2308x2308 (16mb) donde las implementaciones de C se compilaron con gcc y clang usando los flags de optimización `-O0`, `-O1`, `-O2`, `-O3` y `-Os`. Basicamente los flags de `-O#` con `#` un número entre 0, 3 intentan optimizar principalmente para velocidad y luego tamaño, 0 siendo el menos 'optimizado' y 3 el más optimizado, mientras

que -Os optimiza principalmente por tamaño del ejecutable, por ejemplo, luego de hacer un disassembly, notamos que a partir de -O2 gcc ya no armaba un stackframe, ni resguardaba rbp, y pusheaba a medida que necesitaba los registros, alineando rsp cuando fuese necesario usar la pila, diferencias observables entre -O2 y -O3 fue el uso de operaciones SIMD, por ejemplo de empaquetado y desempaquetado, multiplicaciones packed etc en -O3 (para el blur), mientras que esto no pasaba en -O2, extrañamente la performance es la misma y tal vez se debe a otros factores como el modelo de procesador (Intel c2d E840) o que en general gcc hace muchos mas accesos a memoria y estos hacen sombra a la performance ganada por las instrucciones.

A continuación dejamos los gráfico con el promedio (con y sin outliers) de la diferencia bajo distintos flags de optimización y en assembly.

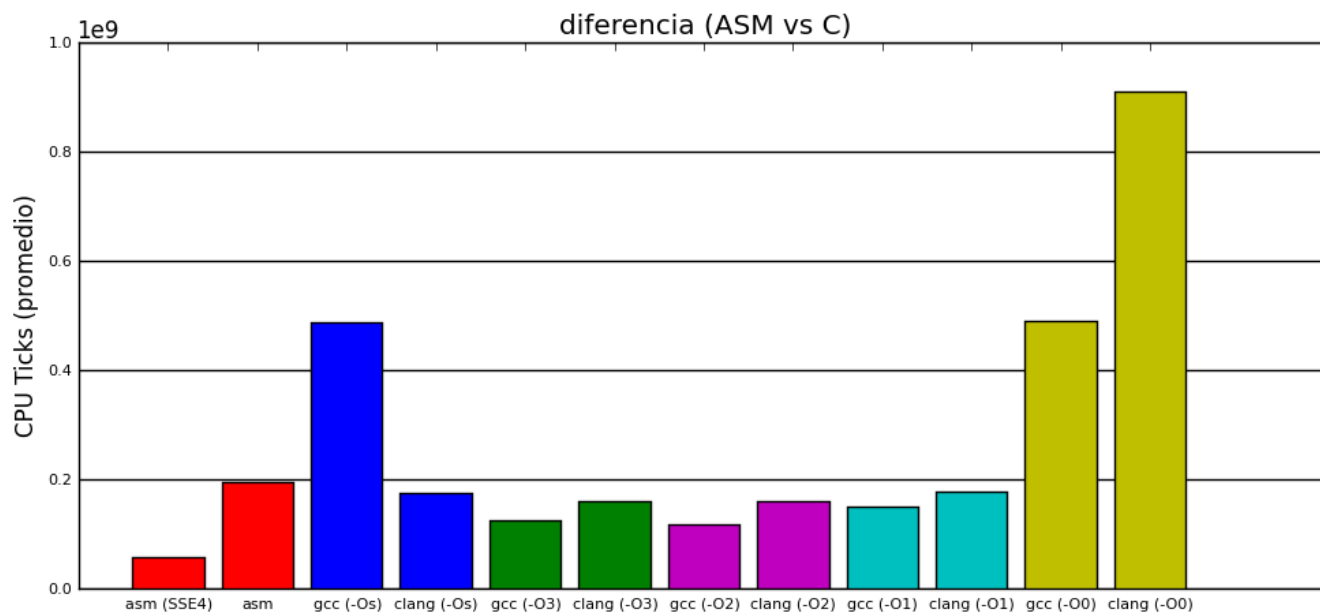


Figura 1: Promedio, 1000 iteraciones sobre una imagen de 2308x2308 pixels de 16mb.

Como podemos observar, la versión en assembler usando instrucciones vectorizadas es más de dos veces mas rapida que cualquiera de las otras implementaciones. En particular es. Otra cosa a observar es que la versión en assembler usando registros de propósito general es más lenta que cualquiera de las versiones -O3 y -O2 de los compiladores, leyendo el manual de optimización de intel vimos en la sección 3.5.1.5 y citamos: `^void ROTATE by register or ROTATE by immediate instructions. If possible, replace with a ROTATE by 1 instruction.` Interesantemente al reemplazar los `ror rax, 8` por `ror rax, 1` y desplegar en 8 instrucciones (4 veces se hacia cada `ror` por lo tanto 24 instrucciones) vimos drásticamente afectada la performance del algoritmo, pero para mal, es decir corre más lento que cualquiera de las otras implementaciones. Dejamos a continuación los valores numéricos del promedio la desviación, la mediana y la esperanza.

Tipo	Esperanza	Desviación	Mediana
<i>asm (SSE)</i>	56.043.648	3.719.499	54.745.299
<i>asm</i>	185.730.157	35.225.868	163.627.996
<i>gcc -Os</i>	483.066.761	86.386.164	425.219.445
<i>gcc -O3</i>	122.860.749	23.118.334	106.125.907
<i>gcc -O2</i>	116.990.809	22.296.448	100.375.353
<i>gcc -O1</i>	152.638.557	28.306.860	133.249.693
<i>gcc -O0</i>	484.505.949	84.107.766	441.267.745
<i>clang -Os</i>	175.719.296	32.586.563	153.610.569
<i>clang -O3</i>	162.637.196	31.045.244	139.688.334
<i>clang -O2</i>	159.943.847	29.501.029	139.728.946
<i>clang -O1</i>	178.052.400	33.145.132	155.390.607
<i>clang -O0</i>	932.036.522	148.813.063	896.191.006

Además de esto escribimos varias versiones de assembler usando registro de propósito general, a las cuales llamaremos asm v1-4. Ahora pasamos a explicar brevemente como estan implementadas.

asm v1: Levanta de a 8 bytes y luego trabaja sobre estos 2 pixeles por medio de shifts rotaciones y dos llamadas a una funcion que calcula la norma infinito de los mismos.

asm v2: Lo mismo que lo anterior, excepto que las rotaciones por immediatos estan 'desenrolladas' por varias llamadas a ror reg, 1, esto viene de que al leer el manual de optimización de intel nos encontramos con y cito: section 3.5.1.5: "avoid ROTATE by register or ROTATE by immediate instructions. If possible, replace with a ROTATE by 1 instruction."


asm v3: Una idea parecida a v1, excepto que en vez de rotaciones usamos puramente shifts.

asm v4: Lo mismo que v3 pero las llamadas a la función que calcula las normas infinitos estan inlineadas

asm v5: Lo mismo que v4, solo que ahora la función que aplica la norma infinito tiene menos instrucciones y opera sobre 4 bytes en vez de 8 por ciclo.

En general se intento evitar accesos a memoria, comparado a lo que hace gcc que son 15+ accesos por iteración, hacemos 3 accesos a memoria pidiendo entre 8 a 4 bytes.

Pasamos todas estas implementaciones sobre 2000 iteraciones sobre una imagen de 16mb de 2308x2308 pixels y obtuvimos los siguientes resultados:



Tipo	Esperanza (ticks)	Desviación (ticks)	Mediana (ticks)
asm (SSE)	56.680.048	2.023.564	56.059.389
asm v5	173.458.584	33.815.428	149.441.206
asm v4	189.075.813	37.004.652	162.500.233
asm v3	197.540.668	38.514.532	169.892.176
asm v2	307.955.171	59.536.896	262.879.128
asm v1	189.969.936	37.223.783	162.727.425
gcc -O3	121.772.855	23.099.911	105.157.858

Como se puede apreciar, la Esperanza (media aritmética sobre el total de iteraciones) de la versión SSE es 2.14 veces más rápida que la version de gcc con flag de optimización -O3, además su desviación es mucho más pequeña

que cualquiera de las otras implementaciones, lo cual muestra que es mucho más estable, esto pasa en general para la mayoría de las implementaciones que hicimos en assembler.

Por otro lado ninguna de las versiones que usan solo registros de propósito general pasan en velocidad a la versión de gcc, creemos que esto se debe a que gcc esta alineando su código por medio de operaciones nops para que tenga mejor branching.

Una de nuestras hipótesis era que el tamaño del cache iba a afectar la performance de nuestro algoritmo. Para esto corrimos la diferencia en Assembly y C sobre imágenes que iban de 256kb a 64mb como se ve en la figura, de vuelta bajo gcc y clang, pero esta vez con el flag de optimización -O2, ya que por el test anterior era el que mejor se comportaba sobre la diferencia.




Figura 2: Diferencia en asm, escala logarítmica

Lo que se obtuvo es una curva que sube suavemente, lo cual implicaría que el algoritmo tiene un crecimiento bastante predecible hasta el tamaño donde se lo probó (imágenes de 4000x4000 pixels con un tamaño de 64mb).




Figura 3: Diferencia en asm, escala no logarítmica

Lo mismo pasa con las implementaciones en C, en este caso gcc con -O2.




Figura 4: Diferencia en C, escala logarítmica

3.2. Blur

Primero corrimos un tests parecido al de diferencia donde probamos todas las implementaciones de blur bajo distintos compiladores y tambien corrimos una versión vectorizada pero que solo trataba un pixel a la vez (sus 4 componentes) esta es llamada v1 y la que operaba 4 pixels (16 bytes) es llamada v2. Todo esto sobre una imagen de 1160x1160, radio = 15 y 100 iteraciones.




Figura 5: Promedio sobre 300 iteraciones del blur aplicado a una imagen de 1160x1160 con radio 3.

Como vemos la versión de assembler que opera sobre 4 pixels es más de 3 veces mas rápida que cualquiera de las versiones de C, y 1.6 veces más rápida que la versión que opera sobre un pixel, el cambio de codigo es entre un pixel y cuatro es mínimo, solo se usan mas registros pero se hacen las mismas operaciones y se cambia un offset, así que no se justificaria nunca el no pasar a operar sobre 4 pixeles.

Tipo	Esperanza	Desviación	Mediana
<i>asm 4px</i>	2.106.291.807	301.117.707	2.168.926.731
<i>asm 1px</i>	3.497.413.560	574.758.539	3.883.153.464
<i>gcc -Os</i>	8.843.585.499	1.578.879.058	10.084.543.303
<i>gcc -O3</i>	9.130.861.305	1.539.043.241	10.196.606.596
<i>gcc -O2</i>	8.896.692.812	1.594.654.086	10.158.618.532
<i>gcc -O1</i>	7.147.828.723	1.206.676.801	7.982.797.657
<i>clang -Os</i>	4.880.678.639	778.651.350	5.377.046.157
<i>clang -O3</i>	4.832.604.511	788.668.977	5.378.602.122
<i>clang -O2</i>	4.800.626.481	791.235.023	5.378.756.337
<i>clang -O1</i>	4.333.126.690	711.630.020	4.833.148.446

Otra cosa a notar es que el rol entre gcc y clang cambió, a diferencia de la diferencia de imagenes donde gcc era siempre mas rápido que clang aca pasa lo contrario, e inclusive la versión de clang en -O1 es la más rápida en general, esto también nos hace pensar que los flags de optimización no siempre son una solución efectiva si lo que se busca es codigo de alta performance. Una de las razones que creemos que c se comporta tan mal con el blur es por los saltos de fila, lo cual nos inclina a decir que ocurren muchos cache misses durante la iteración sobre el kernel, y esto no es la única perdida de performance, sino que además que gcc y clang utilizan el stack para guardar contadores y hacen varias multiplicaciones adentro del ciclo para calcular los offsets dentro de la matriz, lo cual nosotros pudimos evitar totalmente en la versión de assembler.

Otra de las hipótesis que teníamos con blur es que dada una imagen con un radio pequeño iba a correr mas lento que con un radio mas grande, pero a medida que el radio domine la cantidad de pixeles sobre las cuales va a aplicar

la matriz de convolución el tiempo de ejecución iba a bajar. Esto lo pudimos probar corriendo blur sobre una imagen de tamaño fijo (en este caso 584x584 pixels) e incrementando el radio como se ve en la siguiente imagen




Figura 6: Blur, cambiando los radios

El algoritmo llega a un punto crítico cuando el radio es equivalente a la dimensión/2, es decir cuando el algoritmo se comporta como $O(n^4)$ sobre la dimensión, esto es fácil ver ya que dada una matriz cuadrada de tamaño n^2 , si $r \sim n/2$, tenemos que por pixel hace $\sim n^2/2$ operaciones y hay $\sim n^2/2$ pixeles posibles para recorrer.

Al igual que en diferencia también corrimos, esta vez solo la versión assembler de blur sobre imágenes de tamaño 64kb a 32mb, radio 3 y sigma 1, obtuvimos lo siguiente:




Figura 7: Blur, cambiando los radios

Test sobre tamaño

Tipo	Esperanza	Desviación	Mediana
256kb	45.259.012	9.919.790	39.031.906
512kb	88.726.855	17.742.991	76.158.607
1mb	179.615.877	34.107.812	158.408.100
2mb	355.030.668	60.202.083	339.998.922
4mb	688.433.498	102.855.212	677.914.299
8mb	1.411.329.438	196.083.930	1.359.012.604
16mb	2.916.520.352	499.435.056	3.129.296.998
32mb	4.599.736.774	742.362.544	4.478.467.171

4. Conclusión

Para el algoritmo de diferencia, se justificaria totalmente hacer una implementación en SIMD, no solo por el hecho de que corre más de dos veces más rapido que cualquiera de las otras implementaciones, sino que además fue más facil implementarlo que su version de C y todavía mas facil que la versión con registros de propósito general.

Referencias

- [Gav06] Ilya Gavrichenkov. Getting ready to meet Intel Core 2 Duo: Core microarchitecture unleashed. *Xbit Laboratories*, 2006.
- [Int15] Intel. Intel 64 and IA-32 Architectures Optimization Reference Manual. *Intel Corporation*, May, 2015.